Amadou MAMANE

AI Engineer / Data Scientist

CentraleSupélec Alumni

mamanesarki@yahoo.fr
https://amadoumamane.fr
https://github.com/AmadouMamane
+336.52.78.18.48
Vincennes, France
Français

COMPÉTENCES

✓ Techniques

- Frameworks ML — **Scikit-learn**, **Spark ML**, **TensorFlow**, Pytorch, **Vertex AI**, Statsmodels
- Visualisation de données — **Matplotlib**, **Seaborn**, Plotly, Bokeh, **Tableau**, Grafana
- Langages de programmation — **Python**, Numpy, **Pandas**, Scipy, Scala, Java, Shell, **SQL**
- Bases de données — **BigQuery**, **AlloyDB**, Hive, **Pinecone**, Cassandra, Oracle, **Firestore**
- MLOps — Git, **GitLab CI/CD**, **Kubeflow**, **Terraform,** Airflow, **Docker**, **Kubernetes**
- Plateformes big data — **Hadoop**, **Spark**, Flink, **Kafka**, **Nifi**, Streamsets
- Cloud computing — **Google Cloud Plateform, AWS,** Openstack
- IA Générative — GPT,Llama,Gemini,Claude, **ADK**, LangChain**,LangGraph**, LangSmith

✓ Fonctionnelles

- **Statistiques descriptives** et **inférentielles** (estimation, test d'hypothèse), **Séries temporelles**
- **NLP,** Théorie de graphes et analyse de réseaux, **Transformers, RAG, Prompt engineering**
- **Vision par ordinateur, Deep learning, Systèmes de recommandation, IA générative**
- Apprentissage non supervisé, Segmentation, **Méthodologie agile**
- Data engineering, MLOps, **Architecture Data**

✓ Certifications

- C# developer, Septembre 2014
- Applied Data Science Program: Leveraging AI for Effective Decision Making - MIT, Juillet 2024
- Google Cloud Certified - Generative AI Leader, Septembre 2025
- Google Cloud Certified - Professional Machine Learning Engineer, Octobre 2025
- Google Cloud Certified - Professional Cloud Architect, en préparation

✓ Langues

- **Français** — Courant
- **Anglais** — Professionnel

FORMATION

2024 - 2024	**Applied Data Science Program**: Leveraging AI for Effective Decision Making, **MIT**
2014 - 2015	**M.S. Ingénierie des Systèmes Informatiques Ouverts**, Ecole Centrale Paris
2011 - 2012	Master recherche Génie Industriel et Informatique, **Ecole des Mines de Saint-Etienne**

EXPÉRIENCE PROFESSIONELLE

Juin 2025 – Aujourd'hui | **Devoteam GCloud/Thalia, Allemagne**

AI Engineer

Au sein d'une équipe de 8 personnes

- ✓ Développement d'une **plateforme IA** multi-agents pour le support client et la recommandation de produits, centrée sur la conception et l'industrialisation d'un pipeline de vectorisation de données multimodales (texte & images) à grande échelle
  - Conception de l'**architecture technique** sur **GCP**, optimisée pour la **scalabilité**, la **performance** et les **coûts**
  - Construction d'une pipeline de **vectorisation multimodale** (Vertex AI Embeddings, BigQuery ML, AlloyDB)
  - Automatisation CI/CD de bout en bout via GitLab + Terraform
- ✓ Mise en place des briques de **supervision** et d'**observabilité** des **agents**

Environment technique	**LangGraph, Vertex AI Embeddings, Cloud Run Jobs, AlloyDB, BigQuery ML, GitLab CI/CD, Terraform, OpenTelemetry, Cloud Trace, Cloud Logging, Cloud Monitoring**
Environment fonctionnel	**Librairie, retail omnicanal (online + 950 magasins)**

Juillet 2024 – Mai 2025 | **MIT/Projet de recherche appliquée, À distance**

AI Engineer

Au sein d'une équipe internationale de 4 personnes

- ✓ **Conception et développement** d'un système intelligent de **Retrieval Augmented Generation** (RAG) pour l'interrogation en langage naturel de **sources structurées** et **non structurées** (PDF, CSV, HTML, bases SQL)
  - Conception d'un **pipeline automatisé** d'ingestion multi-formats et de préparation des données
    - **Nettoyage documentaire** et stratégie de **chunking robuste** avec fallback par taille de tokens
    - **Enrichissement** des données par **métadonnées exploitables** pour la recherche hybride
  - Mise en place d'un **pipeline de vectorisation** et de recherche sémantique
    - **Embedding** des documents via modèles spécialisés (Hugging Face)
    - **Indexation** dans Qdrant avec support de la **recherche hybride** (similarité vectorielle + recherche lexicale)
    - Implémentation de stratégies de **reranking contextuel** pour améliorer la **pertinence** des documents récupérés
  - **Génération** de réponses fiables et explicables à partir de **LLM open-source**
    - **Génération conditionnée** via LLaMA et Gemma
    - Mise en place d'un **scoring de confiance** pour la **réduction des hallucinations**
    - **Citation** automatique des **sources** et formatage structuré des réponses
    - **+30 % de précision** perçue lors des **évaluations qualitatives**

Environment technique	**LangGraph, LangGraph, Qdrant, FAISS, Nltk, LLaMA, LangChain, Hugging Face Transformers**
Environment fonctionnel	**Recherche appliquée**

Septembre 2023 – Novembre 2024	Cartes Bancaires, Paris

Data scientist

Au sein d'une équipe de 20 personnes

- ✓ Au sein du département de **lutte contre la fraude**, participation au développement d'une solution visant à **sécuriser les transactions bancaires** par la **détection proactive d'attaques** ciblant les e-commerçants
  - **EDA** approfondie pour la détection de **signaux faibles**
  - **Feature engineering** sur des **données transactionnelles massives**
  - Implémentation d'un modèle de **Gradient Boosting (**Spark ML) optimisé pour signaux rares
  - **Industrialisation** complète via PySpark & Oozie
- ✓ **Recommandations** de bonnes pratiques de développement **Apache Spark**

Environment technique	**PySpark, Spark ML, Python, Hive, Impala, Oozie, Git, Séries temporelles, Data leakage**
Environment fonctionnel	**Banque, Lutte contre la fraude**

Avril 2019 – Août 2023	RCI BANK & SERVICES, Paris

Data scientist

Au sein d'une équipe de 30 personnes

- ✓ Participation à la création de la plateforme centrale de gestion des données clients du groupe, et au développement d'applications data et ML stratégiques. Projet accompagné d'une migration des traitements existants d'un cluster Hadoop on-premise vers Google Cloud Platform (GCP)
  - **Conception** et implémentation d'un **score de prédiction** de l'attrition des clients
  - Développement d'un **moteur de déduplication des données** client basé sur **similarité vectorielle & graphe**
  - **Modèles ML**: scoring churn, segmentation, détection de fraude
  - **Industrialisation des traitements** avec des pipelines CI/CD, Airflow et Kubeflow
  - Pilotage de plusieurs projets preuves de concept, **POCs,** pour évaluer et intégrer de nouvelles technologies

Environment technique	**Sckit-learn, Spark ML, Scala, Python, Gitlab CI/CD, GraphFrames, GCP (Vertex AI, BigQuery, Pub/Sub, Cloud Run, Dataproc, Composer), Nifi, Jira**
Environment fonctionnel	**Banque, Risque et crédit, Connaissance client, Méthodologie agile**

Mai 2017 – Mars 2019	Altran/Orange, Arcueil Cachan

ML engineer

Au sein d'une équipe de 20 personnes :

- ✓ Contribution à un projet de **valorisation en temps réel** des **données d'interaction client** sur le réseau mobile (2G, 3G, 4G), avec pour objectif d'**alimenter les applications métiers** et les **services transverses** du groupe
  - Développement d'applications de traitement en temps réel des données réseau, normalisation et diffusion dans un format pivot à l'ensemble des équipes métier
  - Participation au cycle complet de développement logiciel : prototypage, tests, sélection et intégration de composants applicatifs
  - Suivi de l'activité réseau à l'aide de KPIs métiers

- ✓ Mise en production, supervision et maintenance de plusieurs applications critiques

Environment technique	**Kafka, Flink, Spark, Hadoop, InfluxDB, Grafana, Streamsets, Scala, Java, Git, shell**
Environment fonctionnel	**Télécommunications, Connaissance client**

September 2016 – April 2017 **Altran/SNCF, La Défense**

Data scientist

Au sein d'une équipe de 20 personnes :

- ✓ Appui à la stratégie de **yield management** (optimisation de la politique tarifaire) à travers le développement d'**outils d'aide à la décision tarifaire**: prédiction de la sensibilité au prix et prévision des ventes de billets
  - □ **Collecte des données** web de recherches sur les trains
  - □ Développement d'un **modèle** de prédiction de remplissage de la première classe
  - □ Maintenance d'un modèle de prédiction de la sensibilité des trains au prix
  - □ Collecte des données web de recherches sur les trains
- ✓ Contribution à l'**amélioration de la qualité de code et mise en place de bonnes pratiques de développement**

Environment technique	**Scikit-learn, PySpark, Python, Pandas, scala, Spark, Git, Bokeh, Jenkins, Luigi**
Environment fonctionnel	**Yield management, Méthodologie agile**

Novembre 2015 – Septembre 2016 **Altran/Orange, Guyancourt**

Data scientist

Au sein d'une équipe de 30 personnes :

- ✓ Participation à l'implémentation de la solution **Customer Experience Management On Demand** (CEMOD) de Nokia, destinée à la **connaissance client** et à l'**amélioration de la performance du réseau mobile**
  - □ Préparation et transformation des données issues du réseau, de la facturation et du CRM
  - □ Intégration de ces données dans la plateforme CEMOD
  - □ Calcul et prédiction de scores permettant d'évaluer la satisfaction client et la qualité du réseau dans les zones de vie du client
  - □ Contribution à l'anonymisation des données sensibles conformément aux exigences de confidentialité et conformité

Environment technique	**Hive, Pig, Java, Oozie, shell, svn**
Environment fonctionnel	**Télécommunications, Connaissance client**

Avril 2015 – Septembre 2015	Société Générale, Val de Fontenay

Datascientist/Stage

Au sein d'une équipe de 20 personnes :

- ✓ Projet de cybersécurité innovant visant à détecter les attaques par déni de service distribué (DDoS) à partir des logs applicatifs, en rupture avec les approches traditionnelles qui se concentrent sur les indicateurs réseau (volumétrie, paquets, connexions)
  - Recherche sur l'état de l'art des méthodes de détection DDoS basées sur les logs web
  - Nettoyage des données brutes et reconstruction des sessions de navigation
  - Feature engineering et visualisation pour mettre en évidence des patterns anormaux
  - Clustering pour identifier les groupes de sessions de navigation
  - Labélisation semi-automatique des données
  - Développement, entraînement et optimisation de modèles de classification supervisée pour la détection d'attaques

Environment technique	**Hadoop, Scikit-learn, Pig, Hive, Python, Java, Pandas, Numpy, Scipy, Matplotlib, Git**
Environment fonctionnel	**Banque, Méthodologie agile**